

Product Requirement Document (PRD)

Sistem Chatbot Akademik AI (Llama 3.2 3B + RAG)

Proyek: Academic AI Chatbot Backend

Status: Draft Perancangan v1.0

Teknologi Utama: FastAPI, LangChain, ChromaDB, Llama 3.2 3B

1. Ringkasan Eksekutif

Dokumen ini merinci spesifikasi teknis untuk pengembangan sistem backend chatbot cerdas yang dirancang khusus untuk lingkungan akademik. Sistem ini memanfaatkan teknik **Retrieval-Augmented Generation (RAG)** untuk memastikan jawaban yang diberikan berbasis pada dokumen resmi kampus, sehingga mengurangi risiko halusinasi AI.

2. Arsitektur Teknologi (Stack)

Framework	FastAPI (Python 3.10+)
Orchestration	LangChain
Vector Database	ChromaDB (Local Persistence)
LLM Model	Llama 3.2 3B (Quantized via Ollama/GGUF)
Embeddings	HuggingFace BGE-M3 atau OpenAI (Optional)

3. Struktur Proyek (Clean Architecture)

Implementasi menggunakan prinsip *Separation of Concerns* untuk memudahkan skalabilitas dan pengujian.

```
app/
├── api/           # Controller & Route Definition
│   └── v1/       # Endpoint chat, ingest, & health
├── core/         # Configuration & Constants (config.py)
├── services/     # Business Logic (LangChain processing)
│   ├── ai_logic.py
│   └── vector_store.py
├── schemas/      # Pydantic models (Request/Response)
├── repositories/ # Data Access Layer (ChromaDB Wrapper)
└── main.py       # Application Entry Point
```

4. Fitur Utama

4.1. Ingesti Data Akademik

- Dukungan format file PDF, Markdown, dan TXT.
- Pemrosesan teks menggunakan *RecursiveCharacterTextSplitter*.
- Penyimpanan vektor ke ChromaDB dengan metadata kategori dokumen.

4.2. Chatbot & RAG Engine

- **Semantic Search:** Pencarian konteks dokumen paling relevan.
- **Contextual QA:** Llama 3.2 3B menjawab hanya berdasarkan konteks yang diberikan.
- **Streaming Output:** Pengiriman token jawaban secara real-time untuk efisiensi UX.

Catatan Privasi: Seluruh pemrosesan data (LLM & Vector DB) dilakukan secara lokal pada infrastruktur server internal untuk menjamin kerahasiaan data akademik mahasiswa.

5. Kebutuhan Sistem (Hardware)

- **RAM:** Minimal 12GB (Rekomendasi 16GB+ untuk WSL2).
- **GPU:** NVIDIA GPU dengan VRAM minimal 6GB (untuk akselerasi inference).
- **Storage:** SSD untuk akses cepat ke file ChromaDB.

6. Roadmap Pengembangan

1. Fase 1: Setup environment FastAPI & struktur folder.
2. Fase 2: Integrasi ChromaDB & pipeline upload dokumen.
3. Fase 3: Implementasi LangChain RAG dengan Llama 3.2 3B.
4. Fase 4: Optimasi prompt & testing akurasi jawaban akademik.